烯牛政策爬虫平台

项目介绍

> 本项目是"烯牛政策图谱"的**采集与结构化基座**：把分散在中央、国务院、各部委以及 31 省市自治区门户上的产业政策，自动、可追溯地汇集起来，原稿一字不落地留存，再用 AI 拆解为**标准 36 字段 JSON**，最终服务于 LP/GP、银行、券商、企业战投与研究机构的"检索 + 解读 + 统计 + 对比 + 推送"。

1. 项目要解决的问题

痛点

- 政策来源分散在 100+ 网站，版面与字段各异
- 政策正文、附件、元信息不统一，难检索难比对
- 人工运营无法保证覆盖与时效
- 合规与原稿可追溯性是金融客户的硬性要求

交付物

- **稳定可订阅**的政策数据流
- **100% 可回放**的原始页与附件
- **36 字段标准 JSON**（元数据 / 实体内容 / 标签）
- **可审计**：每个字段都能追到原稿与抓取批次

核心指标（MVP 门槛）

维度	指标	门槛	维度	指标	门槛
覆盖	第一阶段入口	⩾ 105 个	解析	JSON schema 合格率	⩾ 90%
鲜度	发布到入库 P95	< 24h	礼貌	host 维度 429/5xx	< 1%
保真	原始页可回放	= 100%	合规	反爬命中后绕过	= 0%

2. 总体架构：双平面设计

系统由**"代码生成平面"**与**"执行平面"**组成，两者通过同一个 Git 仓库串联——**代码合并即上线**。这种结构让"为新网站写适配器"这件繁琐的事可以由 AI 编程代理自动完成，而真正的抓取主路径仍是确定性代码，AI 不进入每一次请求。

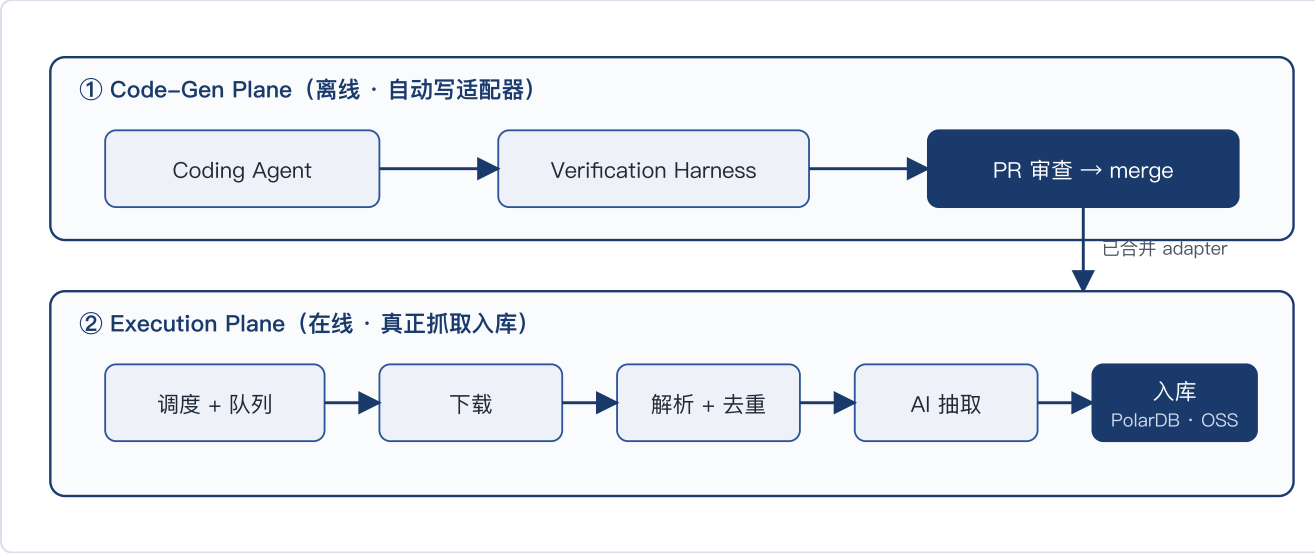

图 1 · 双平面架构：AI 在离线写适配器，在线主路径仍是确定性代码

设计原则

- **控制面自研，数据面复用成熟组件**——抓取/解析/存储用经过验证的库，调度与契约自己掌握。
- **AI 只放在高不确定决策点**——URL 排序、页面分类、反爬识别、字段抽取；规则优先，AI 兜底。
- **抓取层级递进**：feed/sitemap → 静态 HTML → 接口拦截（JSON/GraphQL）→ SSR/DOM → headless 渲染（按需）。命中信号才升级。
- **原始与解析分离**：所有原始字节 + HTTP 元数据落 OSS，可任意回放；解析层独立演进，不影响原稿。

3. 一条政策的生命周期

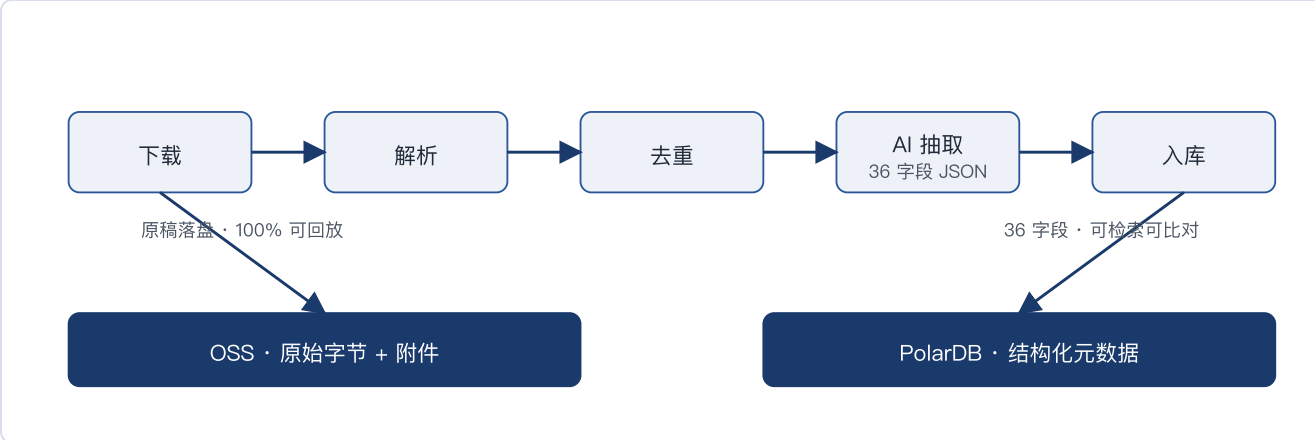

图 2 · 一条政策的生命周期：主链路 5 步，原稿与结构化数据分别归档

1. **提交种子**：人工或定时任务给出网站入口 URL。
2. **礼貌下载**：以 host 为最小限速单元，遵守 robots、Retry-After，遇 429/503 走"Retry-After 优先 + 指数退避 + 抖动 + cooldown"。
3. **原稿落盘**：原始字节直接写 OSS，附件优先按文件名展示。
4. **解析**：调用该 host 对应 adapter，输出列表/详情结构（标题、正文、发布日期、附件）。
5. **去重**：以 `content_sha256` 严格去重；simhash 仅作相似聚类信号，**不自动合并**。

6. **AI 抽取**：将正文 + 网页元数据交给 LLM，输出 36 字段标准 JSON 并校验 schema。
7. **入库**：元数据进 PolarDB，原稿留 OSS，可随时回放与审计。

4. 关键能力模块

能力域	主要 Spec	代码落点	状态
通用爬虫引擎（BFS/DFS · 递归发现 · 翻页）	infra-crawl-engine	`infra/crawl/`	MVP 已实现核心
限流 / 重试 / robots / 反爬识别 / warm-up	infra-fetch-policy	`infra/http · robots · frontier`	MVP 实施
政策业务规格（采集对象 / 6 类数据 / 36 字段）	domain-gov-policy	`domains/gov_policy/adapters · seeds · golden`	MVP 实施
数据模型（21 张表 DDL 唯一权威源）	data-model	`infra/storage/`	MVP 实施
WebUI（任务后台 + 采集监控 + 结果浏览）	webui	`webui/ + webui/frontend/`	React 重写中
Codegen · adapter 输出契约	codegen-output-contract	`infra/agent · harness · adapter_registry`	M3.5 实施
Codegen · 自动合并安全网（tier / canary / 回滚）	codegen-auto-merge	`infra/sandbox · scheduler · codegen`	M3.5 实施
Headless 渲染池	infra-render-pool	`infra/render/`	核心已实现（随 M3.5 codegen 平台落地）
韧性（增量 / checkpoint / DLQ / 心跳）	infra-resilience	`infra/checkpoint · version_guard`	暂缓
可观测（指标 / 告警 / 成本）	infra-observability	`infra/observability · ai/budget`	暂缓
部署（主从分布 / 自建分发）	infra-deployment	`infra/dispatch/`	MVP 单进程，扩展期升级

5. 业务规格摘要：政策数据是什么样的

第一阶段采集范围

- **中央行政机关**：国务院政策文件库 + 要闻
- **国务院部委**：覆盖 8 家目标（发改委 / 工信部 / 财政部 / 人民银行 / 金融监管总局 / 证监会 / 国资委 / 科技部），目前已落地 5 家适配器：ndrc / most / csrc / nfra / sasac
- **地方机关**：31 省市自治区"信息公开 + 要闻 + 政策解读"约 90 个 URL
- **引用**：国家法律法规数据库（仅跳转，不打标签）
- **后期补齐**：金融交易所、行业协会

每条政策的三个组成部分

1. **元数据表格**：网页自带的属性表
2. **正文**：政策主体文本
3. **附件**：PDF 等原始字节（本期不做 PDF→文本）

36 字段 JSON 的三段结构

- **元数据字段（15 个）**：标题、发文字号、发布机关、行政区划、政策工具分类等
- **实体内容字段（9 个）**：金额、期限、对象、条件等
- **标签字段（12 个）**：行业、主题、地域映射等

6. 合规与底线（不可妥协）

不做什么

- 不绕过验证码 / 登录 / 付费墙 / 技术 challenge
- 不使用专为绕过保护设计的工具或库
- 不对 robots 明示拒绝的路径继续抓取（5xx 视为完全禁止）
- 默认不抽身份证号、手机号、邮箱等敏感字段

怎么做

- 识别异常 → 降速 / 暂停 / 人工审核
- 每个采集任务必须填写：用途、责任人、范围
- 从设计起预留 删除 / TTL 链路
- warm-up 分级：新 host 按 10%/30%/60%/100% 阶梯放量，反爬命中即降到 L0+cooldown

7. 仓库结构与工程方法

项目采用 **"单仓 + 文档先行 + 轻量 DDD + 规格驱动开发（SDD）"** 模式，规格、计划、代码、评估证据全部在同一仓库内闭环，方便审计与回放。

```
xiniu-crawler/
├── docs/                    控制面（架构、规格、计划、任务、评估）
│   ├── prod-spec/           11 份长期规格（业务 + infra + codegen）
│   ├── exec-plan/active/    当前执行计划（MVP / codegen-bootstrap / WebUI 等）
│   ├── task/                active/completed/archive 工作流目录
│   ├── prd/  research/      产品原稿与工程视角研究底稿
│   └── eval-test/           评估与回放证据
├── domains//        业务代码（按 bounded context）
│   └── gov_policy/          按部委拆分子模块：ndrc / most / csrc / nfra / sasac,
│                            每个子模块自带 *_adapter.py + *_seed.yaml
├── infra/                   跨业务复用的技术能力（不含业务规则）
│   ├── 采集运行时           crawl / http / robots / frontier / storage / render
│   └── codegen 平台          agent / harness / sandbox / codegen /
│                             adapter_contract / adapter_registry / source_probe
```

```
├── webui/                    FastAPI + React + Ant Design ProComponents
├── scripts/                  仓库级 CLI 入口
└── runtime/                  本地运行时（SQLite / 抓取缓存，gitignore）
```

工作流：每一次改动都走"规格 → 计划 → 任务 → 代码 → 证据"

- **Planner** 锁定上下文与作用域，更新 spec，输出已批准的计划
- **Generator** 实现单个原子任务，更新触达的文档与测试
- **Evaluator** 独立验证，记录 green/red 证据，关闭任务状态
- **Cleaner** 例行整洁、归档噪声，把非紧急债务推后

分支命名 `agent/<type>-YYYYMMDD-<topic>`，任务 ID `T-YYYYMMDD-NNN`，**一支分支 → 一个活跃任务 → 一个 PR**。

8. 当前进展与里程碑

里程碑	内容	状态
M0	项目骨架与工作流闭环	已完成
M1	单源跑通 —— 抓取 / 解析 / 去重 / 原稿落盘的基础链路	基础完成
M2	多源 —— 8 个国务院部委 + 解析层去重	实施中（已落地 5/8 家：ndrc / most / csrc / nfra / sasac）
M3	AI 结构化 —— 36 字段 prompt → JSON 入库	计划中
M3.5	Codegen 平台 —— AI 自动写适配器、加压验证、分级合并；render 池一并落地	实施中
WebUI	任务后台 + 采集监控 + 结果浏览（React + Ant Design ProComponents）	重写中
M5	韧性 / 可观测 / 主从部署	已 spec 化，按需提升

> **价值主张：**我们交付的不是又一份"政策搜索结果"，而是一份 **稳定、可回放、可审计、可订阅**的政策数据资产 —— 让所有依赖政策做决策的人，第一时间拿到最干净、最结构化的那份； 让所有依赖该数据的产品，都建立在能追溯到原稿的地基之上。